

## GAN과 DNN을 활용한 딥러닝 기반의 지능형 개인신용 평가모형

An Intelligent Personal Credit Rating Model based on Deep Learning Using GAN and DNN

---

저자 (Authors)	홍태호, 김성훈, 김은미 Tae-ho Hong, Sung-hun Kim, Eun-mi Kim
출처 (Source)	<a href="#">인터넷전자상거래연구 19(1)</a> , 2019.2, 1-16(16 pages) <a href="#">The Journal of Internet Electronic Commerce Resarch 19(1)</a> , 2019.2, 1-16(16 pages)
발행처 (Publisher)	<a href="#">한국인터넷전자상거래학회</a> Korea Internet Electrornic Commerce Association
URL	<a href="http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07627830">http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07627830</a>
APA Style	홍태호, 김성훈, 김은미 (2019). GAN과 DNN을 활용한 딥러닝 기반의 지능형 개인신용 평가모형. 인터넷전자상거래연구, 19(1), 1-16
이용정보 (Accessed)	성균관대학교 115.145.3.*** 2020/10/22 12:38 (KST)

---

### 저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

### Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

## GAN과 DNN을 활용한 딥러닝 기반의 지능형 개인신용 평가모형†

An Intelligent Personal Credit Rating Model based on Deep  
Learning Using GAN and DNN

홍 태 호\* · 김 성 훈\*\* · 김 은 미\*\*\*  
*Tae-ho Hong · Sung-hun Kim · Eun-mi Kim*

### ... Abstract ...

This study propose an approach for developing credit rating model with imbalanced data using machine learning techniques such as decision trees, neural networks, deep learning, and GAN. We develop a personal credit rating model to resolve an issue from imbalanced data for machine learning by utilized the SMOTE and GAN. Personal credit rating is an important system for personal loans such as FinTech, and has been applied with many deep learning techniques. Therefore, the purpose of this study is to develop an intelligent personal credit rating model based on deep learning that can be effectively used in a small data set. Therefore, in this study, 5 samples of 10,000 data sets are sampled and the size of the data set is increased by utilizing the SMOTE and GAN, which is an over sampling technique. We applied classification techniques such as logit, decision tree, ANN, and DNN. Then, to solve the imbalanced data problems, we applied under sampling, SMOTE, and GAN, and compared which the performance of statistical techniques, machine learning, and deep learning. As a result, deep learning based on personal credit rating model of SMOTE + DNN showed the highest performance with 66.2%.

**Key Words** : FinTech, Deep Learning, Imbalance Data, GAN, DNN

---

논문 접수일 : 2019년 1월 8일, 1차 수정일 : 2019년 2월 13일, 게재 확정일 : 2019년 2월 18일

† 이 논문은 부산대학교 기본연구지원사업(2년)에 의하여 연구되었음.

\* 부산대학교 경영대학 경영학과 교수, 주저자

\*\* 부산대학교 경영대학 경영학과, 공동저자

\*\*\* 부산대학교 경영대학 경영학사 시간강사, 교신저자

## I. 서 론

핀테크(Fintech)는 금융(Financial)과 기술(Technology)의 합성어로, IT기술을 기반으로 모바일 결제, 송금, 온라인 관리 등의 금융 서비스를 제공한다(Lee et al., 2016). 최근 금융권 뿐 아니라 비금융권인 IT기업에서도 핀테크에 대해 높은 관심을 보이고 있으며, 핀테크 비즈니스 시장에서 IT기업은 혁신자의 역할로 변모하고 있다(유현선, 2018). 국내의 핀테크 비즈니스 시장은 아직 초기단계로 많은 벤처 기업들이 도전하고 있으나 이 벤처기업들은 부족한 고객수와 적은 자본금의 문제를 가지고 있다. 그럼에도 불구하고 기존의 핀테크 비즈니스에 대한 연구는 많은 고객수와 충분한 데이터를 기반으로 연구가 진행되었다. 이는 풍부한 데이터를 기반으로 이루어진 연구로 이미 많은 고객수를 보유하고 있는 기존 금융기관의 관점에서 진행된 연구라고 볼 수 있다. 부족한 고객수에 대한 문제는 신용등급 예측모형에서 원활한 학습을 방해하는 요인이며 모형의 예측성과를 향상시키기 위해서도 반드시 해결되어야 하는 핀테크 비즈니스의 특징 중 하나이다.

불균형 데이터는 하나의 범주(class)에 포함되는 데이터의 수가 다른 범주에 포함되는 데이터의 수에 비해 현저히 많거나 적은 경우를 의미하며 소수 범주가 10%이하인 경우 심각한 불균형 데이터라 할 수 있다(He and Garcia, 2009). 불균형 데이터는 기계학습의 성능을 저하시키는 요인으로 이러한 불균형 데이터를 해결하는 방법으로 비용부과, 가중치 수정, 샘플링 등의 방법이 존재한다. 하지만 비용부과와 가중치 수정의 경우 데이터의 불균형성을 없애는 근본적인 해결책이라 할

수 없다. 샘플링은 소수의 범주에 맞추어 다수의 범주를 랜덤으로 추출하는 언더샘플링(under sampling)과 다수의 범주에 맞추어 소수 범주의 데이터를 복원추출하는 오버샘플링(over sampling)이 있으며, 불균형 데이터를 해결하기 위해 기존 연구에서는 언더샘플링이 많이 사용되어왔다(Tomczak and Zieba, 2015; 이균희 외, 2017; Luo et al., 2017). 그러나 덤퍼닝은 데이터 셋의 크기가 클수록 높은 예측 정확도를 보이기 때문에(Buda et al., 2018), 언더샘플링보다 오버샘플링이 선호된다. 따라서 핀테크 비즈니스 기업의 특성을 고려한 신용평가 모형을 위해 데이터 생성 기법을 적용하고자 한다. 이는 새로운 비즈니스를 막 시작한 핀테크 비즈니스 기업의 특성인 부족한 고객 수에 대한 문제를 해결하며 동시에 불균형 데이터 문제를 해결할 수 있다.

본 연구에서는 소규모 데이터에 대한 문제점을 해결하기 위해 SMOTE(Synthetic Minority Over-sampling Technique)와 GAN(Generative Adversarial Networks)을 적용한다. SMOTE는 과적합 문제에서 비교적 자유로운 샘플링 기법이며, 덤퍼닝 기법인 GAN은 최근 비즈니스 문제에 많이 적용되고 있다. 신용평가 연구에서도 덤퍼닝을 활용한 연구가 다수 진행되고 있으며(이균희 외, 2017; Kvamme et al., 2018), 덤퍼닝 기반의 신용평가 모형의 분류 정확도가 기계학습 기반의 신용평가 모형의 분류 정확도 보다 높음을 검증하였다(Tomczak and Zieba, 2015; Kvamme et al., 2018). 따라서 본 연구에서는 SMOTE와 GAN을 활용하여 부족한 고객수 문제를 해결하고 DNN(Deep Neural Networks)을 적용하여 덤퍼닝 기반의 지능형 개인신용 평가모형을 구축한다. 또한, 제안된

방법과 비교하기 위해 데이터 생성기법을 적용하기 전 언더샘플링한 테스트 데이터 셋에서 모형의 예측성과를 비교해 본다.

## II. 선행 연구

### 2.1 개인신용평가

개인신용평가는 연령, 성별, 직업 등과 같은 개인적 특성에 따라 ‘우수 신용’, ‘불량 신용’의 두 가지 분류로 구분하는 이진 분류 문제로 볼 수 있다. 개인신용평가는 금융기관의 대출 심사 과정에서 매우 중요한 시스템으로 개인신용평가의 분류 정확도를 1%만 높여도 모형을 사용하는 이익을 크게 높일 수 있다(Baesens et al., 2003).

과거의 개인신용평가 연구의 경우 단일 분류기의 통계적 기법과 머신러닝 기법이 연구의 주를 이루었으나(Baesens et al., 2003; Yang, 2007), 최근에는 예측성과를 향상시키기 위해 2개 이상의 기법을 동시에 활용하는 앙상블 기법의 연구가 많이 진행되었다. Xia et al.(2017)은 개인신용평가를 위해 비용을 고려한 앙상블 기법인 CSXGBoost (Cost-Sensitive Extreme Gradient Boosting)기법을 제안하였다. 중국의 We.com 데이터와 미국의 lending club 데이터를 적용하여 LR(Logistic Regression), RF(Random Forest)의 기법을 적용하였다. 비용을 고려했을 때와 고려하지 않았을 때의 성과를 비교하였으며 비용을 고려한 앙상블 기법에서 높은 성과를 확인하였다. Feng et al.(2018)은 UCI(University of California Irvine) 기계학습 저장소와 금융기관, Kaggle.com 등에서 수

집한 총 10개의 신용평가 데이터 셋을 이용하여 분석을 진행하였다. DT(Decision Tree), NN(Neural Network), SVM(Support Vector Machine)을 사용하고 앙상블의 최종 결과값을 도출하였으며 제1종 오류와 제2종 오류를 고려한 동적인 앙상블 기법이 실무에 적용되었을 때 오분류 비용을 감소시킬 수 있음을 시사하였다.

앙상블 기법과 더불어 최근 많은 개인신용평가 연구에서 딥러닝 기반의 연구가 진행되고 있으며 딥러닝 기반의 개인신용평가가 머신러닝 및 통계기반의 개인신용평가에 비해 좋은 성과를 보이는 것을 검증하였다(Tomczak and Zieba, 2015; 이군희 외, 2017; Luo et al., 2017; Kvamme et al., 2018). 이군희 외(2017)는 2015년 lending club의 사용자 421,097명의 데이터를 사용하여 CNN(Convolutional Neural Network)을 적용하였다. 데이터의 형상을 무시하는 기존 신경망 모형의 문제점을 해결하기 위해 데이터의 형상을 유지하는 CNN 기법을 적용하였으며 정상과 불량에 대해 다른 데이터 형상을 보일 것이라 예상하고 분석을 진행하였으며 높은 분류 정확도를 확인하였다. Kvamme et al.(2018)은 노르웨이의 가장 큰 금융 서비스 그룹인 DNB의 데이터를 사용하여 일 단위 수준으로 구성된 시계열 데이터를 바탕으로 CNN 컨볼루션 계층의 필터를 시계열에 적용한 결과 다른 방법론에 비해 CNN 기법이 보다 높은 예측 정확도를 가지는 것을 검증했다. 또한 데이터 크기에 따른 CNN 성과를 비교 했는데 학습용 데이터 셋의 크기가 클수록 CNN의 예측 정확도가 높아지는 결과를 보였다. 따라서 CNN과 같은 딥러닝 기법들은 많은 데이터 셋을 통해 학습했을 경우

더 높은 예측 정확도를 가지게 되는 것을 확인할 수 있었다.

## 2.2 심층신경망

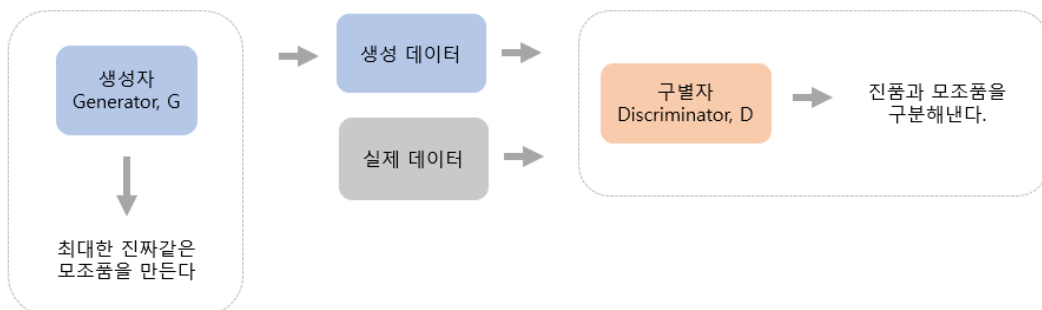
심층신경망(DNN)은 딥러닝에서 가장 기본적인 기법으로 인공지능망에서 은닉층의 수가 2개 이상인 경우를 심층신경망이라 한다. 기존의 인공신경망보다 더 많은 층을 사용하고 특성을 추가하여 특화된 데이터에 대한 표현 능력을 크게 증가시켰으며(Hinton et al., 2006), 패턴인식이나 추론 등의 학습에 많이 사용된다. 심층신경망은 하나의 입력층과 하나의 출력층을 가지고 있는 점은 인공신경망과 같지만 두 개 이상의 은닉층을 가지고 있는 것이 특징이다. 여러 개의 은닉층으로 다양한 비선형 변환 기법을 조합하여 높은 수준의 추상화가 가능하다.

LeCun(1989)는 오차 역전파 알고리즘에 기반해 수기로 쓰여진 우편번호를 인식하는 심층신경망을 소개하였다. 알고리즘은 성공적으로 실행되었지만 모형의 학습 시간이 매우 오래 걸리기에 실용적인 문제로 일반화하기에는 어려운 것으로 여겨졌다. 하지만, 하드웨어의 발전과 다양한 활성화 함수의 연구, 드롭아웃

알고리즘 등을 통해 과적합 문제, 학습시간 등에 대한 문제가 해결됨에 따라 최근에는 심층신경망에 대한 연구가 활발히 진행 중이다(Loureiro et al., 2018; Kim et al., 2017). Kim et al.(2017)은 침입탐지 연구를 위해 KDD Cup 99 Dataset을 이용하여 DNN을 사용하였으며 우수한 침입데이터 탐지율과 정확도를 보여주었다. 심층신경망은 비즈니스 데이터뿐만 아니라 음성인식, 이미지 분류, 교통, 생물, 병원 등의 다양한 분야에서 사용되고 있다. Loureiro et al.(2018)은 패션산업에서 정확한 판매예측을 위해 DNN을 적용하였으며 높은 예측성능을 검증하였다. Mahmoudi et al.(2018)은 주식시장에서 투자자의 심리를 예측하기 위해 DNN을 적용하였으며 높은 예측성능을 검증하였다.

## 2.3 GAN

GAN은 2014년 Ian Goodfellow이 제안한 딥러닝 기법이다. DNN, CNN 등의 딥러닝 기법이 분류 및 예측, 인식 분야에서 활용되고 있다면 GAN은 데이터를 생성하는 딥러닝 기법으로 불균형 데이터 문제를 해결하는데 활용되고 있다.



<그림 1> GAN 알고리즘

GAN은 생성자(generator)와 구별자(discriminator)로 구성되며 생성자는 데이터를 생성하는 역할을 맡으며 구체적으로 주어진 데이터와 최대한 진짜같은 모조품을 생성하는 역할을 한다. 이후 생성된 데이터는 주어진 실제의 데이터와 구별자에 의해 판별되는 과정을 겪는데 생성자에 의해 생성된 데이터가 주어진 실제의 데이터와 구별할 수 없을 때까지 학습하고 구분이 불가능 한 경우 생성 데이터를 결과값으로 도출하는 구조로 이루어져 있다. 생성자와 구별자는 상호작용을 통해 학습하고 학습을 진행할수록 지속적으로 생성 데이터를 학습하는 과정을 통해 강건성을 갖게 된다(Goodfellow et al., 2014).

<그림 1>는 GAN의 알고리즘을 도식화 한 것이다. 생성자를 지폐 위조범이라 가정한다면 지폐와 똑같은 위조지폐를 만들기 위해 지속적으로 학습하고 구별자는 경찰이 되어 위조 지폐와 지폐의 진위를 가리기 위해 노력하는 것으로 설명할 수 있다. 위의 개념을 식으로 표현하면 식 <1>과 같다.

$$\min G \max D V(D, G) = \\ Ex \sim p_{data}(x)[\log D(x)] \\ + Ez \sim pz(z)[\log(1 - D(G(z)))] \\ <1>$$

$x \sim p_{data}(x)$ 는 실제 데이터에 대한 확률 분포에서 샘플링한 데이터이며  $z \sim pz(z)$ 는 임의의 노이즈에서 샘플링한 데이터를 의미한다.  $D(x)$ 는 판별자이며  $D(G(z))$ 는  $G$ 가 만들어낸 데이터인  $G(z)$ 가 진짜라고 판단되면 1, 가짜라고 판단되면 0의 값을 가진다. 또한 생성자  $G$ 에 넣어 만든 데이터를 판별자  $D$ 가 진짜라고 판단하면 1, 가짜라고 판단하면 0의

값을 가지며 이를 정리하면  $V(D, G)$ 에 대한 min-max 문제를 해결하는 것과 일치한다.

비즈니스 데이터에 GAN을 활용한 연구는 비교적 최근에 시작되었으며 불균형 데이터 문제를 해결하는데 사용되고 있다. 안철휘 외(2018)는 기업의 부도예측을 위해 GAN을 적용하였다. 건전기업에 비해 현저히 적은 부실기업의 데이터에 GAN을 적용하여 불균형 문제를 해결하였다. 홍승진 외(2017)는 모바일 게임 데이터의 불균형 문제를 해결하기 위해 GAN을 적용하였으며 랜덤 포레스트 기법을 적용하여 성과를 평가하였다. 또한 GAN 알고리즘이 오버샘플링, 데이터 생성 알고리즘 보다 높은 분류 정확도를 가지는 데이터 셋을 생성하는 것을 검증하였다(홍승진 외, 2017; 안철휘 외, 2018). Douzas et al.(2018)은 GAN의 확장모형인 cGAN(Conditional version of Generative Adversarial Networks)을 제안하여 실제 데이터의 분포와 근사하게 불균형 데이터의 소수범주 데이터를 생성하여 데이터의 품질을 향상시킬 수 있음을 보여주었다.

## 2.4 SMOTE

언더샘플링은 결과변수가 소수인 범주에 맞추어 다수의 범주 데이터를 랜덤으로 추출하는 샘플링 기법으로 정보 손실의 문제점이 존재한다(He and Garcia, 2009). 이러한 정보 손실의 문제점은 딥러닝의 경우 치명적인 손실로 예상되는데 딥러닝의 경우 데이터의 크기가 클수록 높은 예측 정확도를 보이기 때문이다(Buda et al., 2018).

SMOTE는 소수 범주의 개체를 중심으로 최근 이웃(k-NN)을 합성하여 새로운 관측치를 생성하는 데이터 생성 샘플링 기법이다.

k-NN 기법을 활용하여 새로운 관측치를 생성하는 기법으로 오버샘플링의 과적합 문제에서 자유롭다는 장점이 있다. SMOTE는 임의로 결과 변수 중 소수의 범주 개체 하나를 선택하고, 선택한 개체와 최근접 이웃 간의 거리를 계산한 후, 0과 1사이의 난수를 생성하여 계산한 거리와 곱하여 새로운 관측치를 합성하는 과정으로 이루어진다.

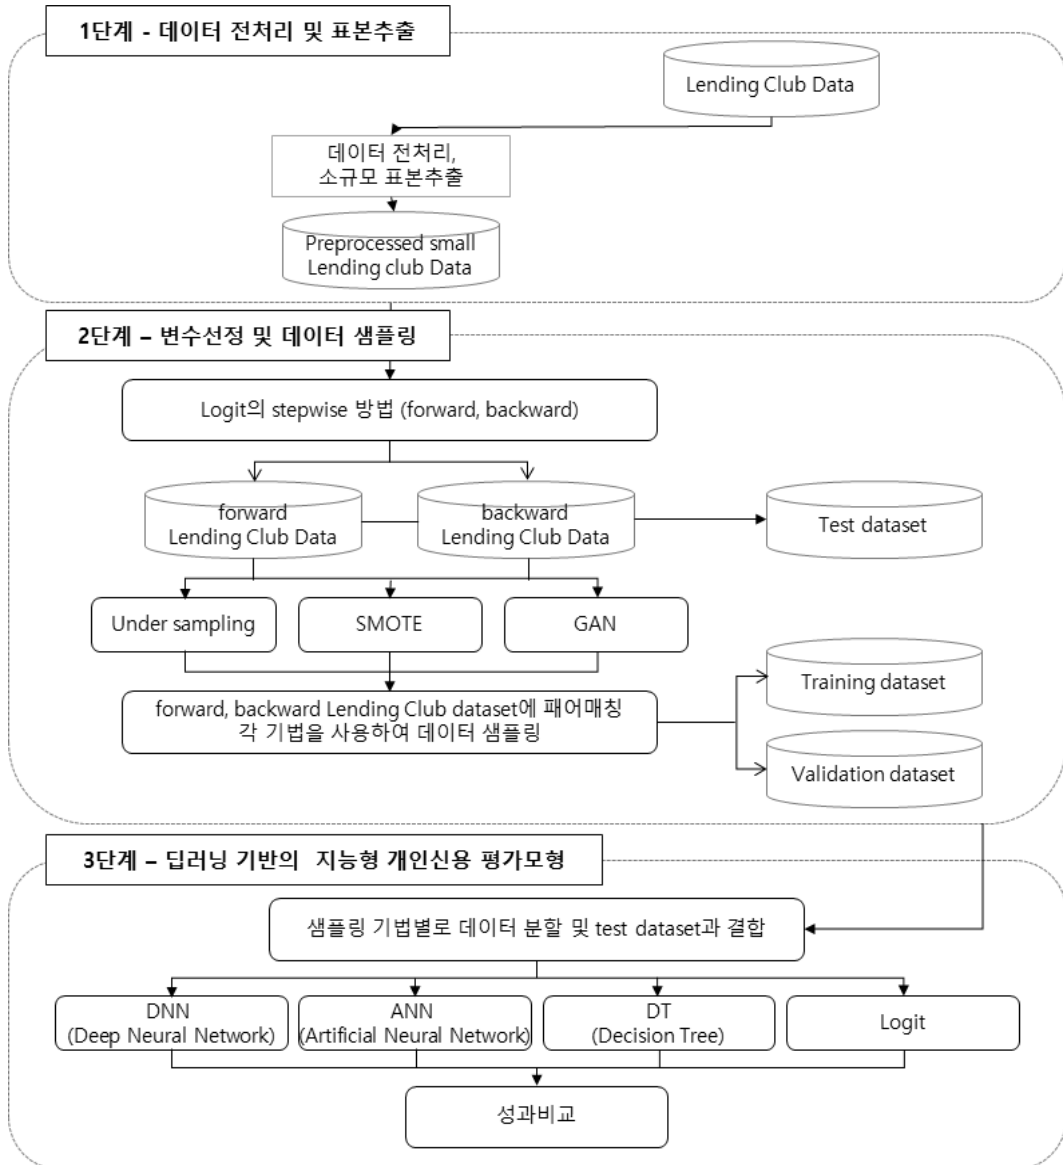
이는 결과 변수 중 다수의 범주 데이터를 모두 사용할 수 있어 정보 손실의 문제가 발생하지 않는다는 장점이 있다. 본 연구에서는 불균형 데이터에 대한 문제와 핀테크 비즈니스 기업이 가지는 특징인 부족한 고객 수에 대한 문제를 SMOTE 기법을 활용하여 동시에 해결한다. 또한 딥러닝 기법은 데이터 세트 크기에 영향을 받기에 언더샘플링 기법에 비해 오버샘플링 기법을 적용하여 높은 예측 정확도를 가지는 데이터를 구축할 수 있을 것으로 판단된다.

김량형 외(2016)는 기업부실화 예측 모델을 개발하기 위해 초기 불균형 상태에서 SMOTE를 적용하여 균형데이터로 데이터를 구성하였다. 단일 분류 학습 알고리즘부와 앙상블 기법 등 다양한 데이터마이닝 기법을 적용하였으며 균형데이터에서 기업부실화 예측률을 향상시킬 수 있었다. Jeatrakul et al.(2010)은 소수범주의 분류 정확도를 높이기 위해 SMOTE를 적용하였으며 인공신경망, k-NN, SVM 등을 적용하여 불균형에 대한 문제를 해결함으로써 성능을 향상시킬 수 있음을 보여주었다. Douzas et al.(2018)도 데이터의 불균형 문제를 해결하기 위해 SMOTE를 적용하여 데이터의 불균형 문제를 해결하였다.

### III. 연구 프레임워크

본 연구의 연구모형은 <그림 2>와 같이 데이터 전처리 및 표본추출, 변수선정 및 샘플링, 딥러닝 기반의 개인신용 평가모형의 3단계로 구성된다. 대출 데이터는 대출 승인 후 생성되는 변수가 존재하며 이를 모형구축에 사용할 경우 예측성과는 높아지지만 일반화의 가능성이 매우 낮아진다. 따라서 본 연구에서는 대출 승인 후 생성된 변수를 제외한다. 또한 단일값을 가지는 변수는 의미를 지니지 못하며 범주형 변수의 경우 가변수화 하여 모형구축에 사용하였으나 범주가 50개 이상일 경우 차원 증가의 문제로 인해 범주가 50개 이상인 변수는 제외한다. 이후, 핀테크 비즈니스 기업의 부족한 고객 수의 특성을 고려하여 10,000개의 소규모 데이터를 추출하고 모형의 일반화 가능성을 높이기 위해 본 연구에서는 5개의 소규모 데이터를 추출한다.

2단계에서 모형구축을 위한 변수선정을 위해 로짓의 stepwise를 적용한다. stepwise의 forward와 backward를 통해 변수를 선정하며 1단계에서 추출된 10,000개의 데이터에 언더샘플링과 SMOTE, GAN 기법을 적용한다. 신용평가의 우량과 불량에 이진 분류에서 대부분의 샘플은 우량인 경우가 많아서 데이터마이닝 기법을 적용한 기계학습에서는 분류하고자 하는 두 집단의 비율을 동일하게 강제로 조정하게 된다. 이 과정에서 대부분 우량샘플을 기계학습에 사용하는 신용불량의 샘플 수만큼 언더샘플링하여 모형을 개발한다. SMOTE와 GAN은 소수 범주의 데이터를 생성하는 기법으로 SMOTE와 GAN 적용 이후 데이터 셋 간의 데이터 크기 차이가 존재하기 때문에 패어매칭하여 모형을 구축한다. 마지



<그림 2> 연구모형

막으로, 구축된 모형의 성능을 평가하기 위한 평가용 데이터는 데이터 생성 단계 전의 데이터 셋에서 추출하였으며 불균형 데이터를 해결하기 위해 일반적으로 많이 사용되는 언더샘플링을 사용한다.

3단계에서는 DNN, 인공신경망, 의사결정나무, 로짓을 적용하여 모형을 구축한다. 언더샘플링을 통해 구축한 DNN 모형은 CU\_DNN (Credit rating model using Under sampling for DNN), 인공신경망 모형은



CU\_ANN(Credit rating model using Under sampling for ANN), 의사결정나무 모형은 CU\_DT(Credit rating model using Under sampling for DT), 로짓모형은 CU\_Logit (Credit rating model using Under sampling for Logit)로 나타내며, SMOTE를 통해 구축한 DNN 모형은 CS\_DNN(Credit rating model using SMOTE for DNN), 인공신경망 모형은 CS\_ANN(Credit rating model using SMOTE for ANN), 의사결정나무 모형은 CS\_DT(Credit rating model using SMOTE for DT), 로짓모형은 CS\_Logit (Credit rating model using SMOTE for Logit)으로 나타낸다. 2단계를 통해 추출된 데이터 셋을 활용하여 모형을 구축하며 평가용 데이터 셋을 통해 예측성과를 비교한다.

## IV. 실험 및 결과분석

### 4.1 실험 데이터

본 연구에서는 대출형 크라우드 펀딩 기업인 Lending Club의 2016년부터 2018년 1분기까지의 1,000,000개 데이터를 사용하였다. Lending Club데이터의 변수는 총148개이며 이중 FICO 점수와 관련된 6개의 변수가 존재하지 않아 실제 데이터에는 142개의 변수가 존재한다. 또한, 대출 신청 당시에는 존재하지 않지만 대출 승인 후 생성되는 변수는 38개이며 예를 들어 recoveries와 같은 변수의 경우 추심(charge off)된 금액 중 회복된 금액을 설명하는 것이기 때문에, 이 값이 0 이상이면 이미 신용불량이 된 고객이다. 이는 모형의 과적합에 영향을 미치는 변수로 판단되며 모형의

일반화를 위해 대출 승인 후 생성된 38개의 변수는 제외하였다. 최빈값의 빈도가 99% 이상인 단일값을 가지는 변수와 결측치가 40% 이상인 변수는 제외하였으며 범주형 변수의 경우 가변수화하여 모형구축에 사용하였으나 범주가 50개 이상일 경우 차원 증가의 문제로 인해 범주가 50개 이상인 변수는 제외하고 분석에 사용하였다.

### 4.2 데이터 표본추출

대부분의 핀테크 비즈니스 기업은 짧은 기간 내에 충분한 신용불량 고객에 대한 데이터 베이스를 확보하기 어렵기 때문에 최대한 적은 수의 데이터 표본으로 개인 신용평가모형을 개발하는 것이 바람직하다. 이러한 특징을 반영하여 10,000개의 데이터 셋 5개를 표본으로 추출하였다. 10,000개의 데이터 셋은 데이터 생성 샘플링 기법인 SMOTE와 GAN을 활용하여 부족한 고객 수에 대한 문제를 해결함과 동시에 불균형 데이터 문제를 해결한다. SMOTE의 경우 k-NN 기반의 데이터 생성 샘플링 기법이기에 k의 개수를 설정해야하며 본 연구에서는 k를 5로 설정하였다. 모형의 성과를 측정할 평가용 데이터 셋은 우량등급 100, 불량등급 100개로 총 200개로 구성되며 모든 데이터 셋에 동일하게 활용하였다.

### 4.3 변수선정 및 샘플링

변수선정을 위해 t-test와 로짓의 stepwise를 적용하였다. 먼저 t-test를 통해 우량등급과 불량등급 집단간에 변수별 평균의 차이가 유의미한지를 검정하여 입력변수를 먼저 선정하고, 선정된 변수를 대상으로 로짓의

&lt;표 1&gt; 최종 선정 변수

변수명	설명	forward	backward
loan_amnt	대출자가 대출 신청한 금액	0	
term	대출금 상환 횟수 범주		0
int_rate	대출 금리	0	0
emp_length	재직 기간 10년 이상	0	0
home_ownership	대출자의 주택 소유 상태 (MORTGAGE)	0	
annual_inc	가입 시 대출자가 자체 기입한 연간 소득.	0	
purpose	대출 신청을 위해 대출자가 체크한 대출 목적 카테고리(debt_consolidation)		0
delinq_2yrs	지난 2년 동안 대출자의 신용 기록에 연체가 발생한 날이 30일 이상 지속된 횟수		0
revol_util	리볼빙 서비스 이용률 또는 대출자가 사용 가능한 모든 리볼빙 신용과 관련하여 사용한 신용 금액.		0
application_type	개인 대출 신청자 또는 두 명의 공동 대출 신청자를 구분하는 지표	0	0
open_act_il	현재 활성화된 할부 계좌(credit) 수	0	
open_rv_24m	지난 24 개월 동안 개설된 리볼빙 계좌(credit) 수	0	
max_bal_bc	모든 리볼빙 계좌에서 가장 많이 사용한 금액		0
all_util	모든 계좌에서 신용 한도 대비 사용한 금액	0	
acc_open_past_24mths	지난 24 개월 동안 개설된 계좌(credit)의 수		0
num_op_rev_tl	열려있는리볼빙 계좌의 수	0	0
num_rev_accts	리볼빙 계좌의 수	0	0
num_tl_90g_dpd_24m	지난 24 개월 동안 90일 이상 연체된 계좌 수		0
num_tl_op_past_12m	지난 12 개월 동안 개설된 계좌 수	0	
pct_tl_nvr_dlq	연체가 전혀 없는 계좌(credit) 비율		0
total_bc_limit	총 은행 카드의 상한 신용 한도	0	
grade_B	LC에서 대출자에게 부여한 대출 등급 (B)		0
grade_C	LC에서 대출자에게 부여한 대출 등급 (C)	0	0
grade_D	LC에서 대출자에게 부여한 대출 등급 (D)		0
grade_E	LC에서 대출자에게 부여한 대출 등급 (E)		0
grade_F	LC에서 대출자에게 부여한 대출 등급 (F)		0
grade_G	LC에서 대출자에게 부여한 대출 등급 (G)		0

stepwise를 이용하여 최종 입력변수를 선정하였다. stepwise를 통해 최종 입력변수를 선정하기 위해 forward방법과 backward방법을 모두 이용하였으며, 입력변수는 <표1>과 같다.

본 연구에 사용된 Lending Club 데이터의 경우 우량등급이 전체의 약 7%인 불균형 분포를 비율을 가지고 있으며 이러한 불균형 데이터는 모형의 학습에 부정적인 영향을 미친다. 따라서 본 연구에서는 표본추출 단계에서

랜덤으로 추출된 10,000개의 5개 데이터 셋에 CU\_Logit, CU\_DT, CU\_ANN, CU\_DNN, CS\_Logit, CS\_DT, CS\_ANN, CS\_DNN의 모형을 구축하였다. 10,000개의 데이터 셋 중 약 800개는 소수범주로 나타나며 다수범주의 데이터를 랜덤으로 추출하여 균형데이터로 맞추어 CU\_Logit, CU\_DT, CU\_ANN, CU\_DNN 모형을 구축한다. CS\_Logit, CS\_DT, CS\_ANN, CS\_DNN 모형의 경우는 이와 반대로 약 800개의 소수범주 데이터를 SMOTE 기법을 활용하여 데이터를 생성하여 소수범주 데이터를 다수범주 데이터와 균형을 맞춘다.

#### 4.4 모형 학습 및 결과 분석

본 연구에서는 활용된 데이터 셋 5개에 대해서 로짓의 stepwise 방식인 forward, backward의 2가지 변수선택을 적용하여 CU\_Logit, CU\_DT, CU\_ANN, CU\_DNN, CS\_Logit, CS\_DT, CS\_ANN, CS\_DNN의 모형을 학습하였다. 학습 이후 표본 추출 과정에서 추출된 평가용 데이터 셋을 활용하여 모형의 성과를 평가한다.

##### 4.4.1 로짓을 활용한 개인신용 평가모형

<표 2>는 로짓모형의 예측성과이다. forward와 backward에 따라 예측성과가 약간의 차이를 보이는 것을 볼 수 있다. 로짓모형의 경우 forward가 더 높은 예측 정확도를 보이고 있으며 forward의 경우 CS\_Logit 모형이 CU\_Logit 모형에 비해 약 0.1% 정도의 성과 차이를 보이고 있다. backward의 경우 CU\_Logit 모형이 59.7%, CS\_Logit 모형이 60%로 CS\_Logit 모형과 0.3% 차이를 보이며 조금 더 높은 예측성과를 보였다.

##### 4.4.2 의사결정나무를 활용한 개인신용 평가모형

<표 3>은 의사결정나무의 예측성과이다. 의사결정나무에서는 forward에서 평균 59.5%, backward에서는 56%의 예측성과를 보이며 다른 모형에 비해 낮은 성과를 보였다. 모든 모형에서 비슷한 예측성과를 보이고 있으며 forward가 약 3%정도 높은 예측성과를 보였다.

<표 2> 로짓모형 예측성과

샘플링 변수선택	CU_Logit				CS_Logit			
	forward		backward		forward		backward	
	학습용	평가용	학습용	평가용	학습용	평가용	학습용	평가용
set1	64.57%	62.00%	63.61%	61.00%	66.06%	63.00%	64.61%	60.50%
set2	64.79%	62.00%	61.51%	59.00%	63.22%	59.50%	61.76%	60.00%
set3	63.67%	60.50%	64.28%	60.00%	62.65%	60.00%	62.97%	59.00%
set4	60.89%	57.00%	60.89%	59.00%	62.14%	58.50%	62.9%	60.00%
set5	64.72%	61.00%	63.08%	59.50%	63.35%	61.00%	63.39%	60.50%
평균	63.78%	60.50%	62.67%	59.70%	63.48%	60.40%	63.12%	60.00%

&lt;표 3&gt; 의사결정나무 예측성과

샘플링 변수선정	CU_DT				CS_DT			
	forward		backward		forward		backward	
	학습용	평가용	학습용	평가용	학습용	평가용	학습용	평가용
set1	62.34%	59.50%	62.11%	56.00%	61.37%	59.50%	59.26%	56.00%
set2	63.17%	59.50%	61.37%	56.00%	61.77%	59.50%	59.46%	56.00%
set3	61.34%	59.50%	58.3%	56.00%	60.98%	59.50%	59.06%	56.00%
set4	61.1%	59.50%	56.89%	56.00%	60.43%	59.50%	57.48%	56.00%
set5	61.82%	59.50%	56.44%	56.00%	61.26%	59.50%	58.23%	56.00%
평균	61.95%	59.50%	59.02%	56.00%	61.16%	59.50%	59.69%	56.00%

4.4.3 인공신경망을 활용한 개인신용 평가 모형

63.5%의 예측성과를 보여 약 2.3%의 예측성과 차이를 보이고 있다.

<표 4>는 인공신경망의 예측성과이다. 인공신경망의 경우 로짓과 의사결정나무와 달리 CS\_ANN 모형과 CU\_ANN 모형 간 예측성과에 차이를 보였다. forward의 CU\_ANN 모형은 60%의 평균 예측성과를 보이며 forward의 CS\_ANN 모형은 62%로 약 2%의 예측성과 차이를 보이고 있다. backward의 경우에도 샘플링 기법별 차이를 보이며 backward의 CU\_ANN 모형의 61.2%의 평균 예측성과를 가지며 backward의 CS\_ANN 모형의 경우

4.4.4 DNN을 활용한 개인신용 평가모형

<표 5>은 DNN의 예측성과로 다른 모형보다 높은 예측성과를 보인다. forward의 CU\_DNN 모형은 61.3%의 예측성과를 보이며 forward의 CS\_DNN 모형은 62.9%로 약 1% 더 높은 예측성과를 보이고 있다. 이러한 CU\_DNN과 CS\_DNN 모형의 성과 차이는 backward에서 더욱 크게 나타나는데 backward의 CU\_DNN 모형의 경우 62.1%의

&lt;표 4&gt; 인공신경망 예측성과

샘플링 변수선정	CU_ANN				CS_ANN			
	forward		backward		forward		backward	
	학습용	평가용	학습용	평가용	학습용	평가용	학습용	평가용
set1	64.33%	61.00%	65.04%	60.50%	66.14%	61.50%	66.04%	63.50%
set2	65.59%	61.00%	63.36%	61.50%	64.79%	64.00%	64.39%	63.50%
set3	61.74%	59.50%	64.02%	61.50%	65.26%	62.00%	64.85%	63.50%
set4	61.46%	60.50%	64.02%	61.50%	63.18%	62.00%	64.88%	64.50%
set5	65.5%	58.00%	65.12%	61.00%	65.74%	60.50%	65.8%	62.50%
평균	63.72%	60.00%	64.31%	61.20%	65.02%	62.00%	65.19%	63.50%

&lt;표 5&gt; DNN의 예측성과

샘플링 변수선정	CU_DNN				CS_DNN			
	forward		backward		forward		backward	
	학습용	평가용	학습용	평가용	학습용	평가용	학습용	평가용
set1	66.08%	63.00%	66.64%	63.50%	68.90%	65.00%	70.74%	66.00%
set2	62.50%	60.50%	64.40%	60.00%	64.46%	64.00%	68.23%	68.00%
set3	65.53%	61.00%	64.92%	61.00%	67.69%	61.50%	69.21%	66.00%
set4	59.79%	61.00%	64.84%	64.50%	62.92%	61.50%	70.53%	65.50%
set5	62.50%	61.00%	64.86%	61.50%	65.93%	62.50%	70.77%	66.00%
평균	63.28%	61.30%	65.13%	62.10%	65.98%	62.90%	69.89%	66.30%

평균 예측성결과를 보이고 있으나 backward에서 CS\_DNN 모형의 경우 66.3%로 약 4.1%의 예측성과 차이를 보인다. 이러한 차이는 두 가지의 이유에서 발생된다고 판단되는데 첫째는 CS\_DNN 모형과 CU\_DNN 모형의 샘플링 후 데이터 셋 크기 차이, 둘째는 DNN의 특성으로 인공신경망에 비해 더 많은 은닉층을 보유하고 있기에 모형의 복잡성이 증가하고 이에 따라 데이터 셋 내부의 패턴을 더욱 정확하게 학습 했다고 예상된다.

#### 4.4.5 GAN 활용 모형별 예측성과

GAN 기법의 경우 소수집단의 데이터가 어느 정도 존재하여 모형이 학습할 수 있어야 성

공적인 데이터를 생성할 수 있다. 하지만 본 연구에서 사용된 10,000개의 표본 중 소수집단 700개는 GAN을 학습시키기에 매우 적은 데이터로 생각된다. 따라서 본 연구에서는 GAN 기법의 샘플링 기법으로써 활용가능성을 확인하기 위해 총 200,000개의 데이터 세트에서 따로 실험하였다. 데이터 생성의 정도는 1.5배, 2배, 4배, 8배로 구분하여 실험 하였으며 생성이후 원본의 데이터와 합친 후 불균형 데이터 문제의 해결을 위해 언더샘플링을 활용하여 균형데이터로 하였다.

<표 6>는 GAN을 이용한 모형별 예측성과이다. GAN 기법의 경우 소수집단의 데이터를 1.5배, 2배, 4배, 8배로 나누어 실험했는데 인공신경망과 DNN 모형에서 1.5배, 2배로 데이

&lt;표 6&gt; GAN을 이용한 모형별 예측성과

샘플링	GAN							
	로짓		의사결정나무		인공신경망		DNN	
	학습용	평가용	학습용	평가용	학습용	평가용	학습용	평가용
Under	64.92%	64.00%	64.25%	64.40%	64.69%	62.95%	64.82%	63.50%
GAN X 1.5	66.99%	63.25%	62.76%	64.40%	66.95%	63.10%	69.60%	63.65%
GAN X 2	65.42%	63.90%	61.94%	64.40%	65.54%	63.55%	72.58%	62.65%
GAN X 4	65.22%	64.05%	60.44%	64.40%	65.30%	62.55%	77.82%	58.90%
GAN X 8	64.43%	59.75%	60.96%	64.40%	64.57%	60.05%	84.89%	54.60%

&lt;표 7&gt; set1의 McNemar 검증 결과

set1	CU_DT	CU_ANN	CU_DNN	CS_Logit	CS_DT	CS_ANN	CS_DNN
CU_Logit	35.21*** (0.00)	33.58*** (0.00)	29.03*** (0.00)	0.3 (0.57)	25.88*** (0.00)	33.02*** (0.00)	37.5*** (0.00)
CU_DT		2.52 (0.11)	7.84*** (0.00)	31.55*** (0.00)	0.01 (0.91)	4.5** (0.03)	0.27 (0.6)
CU_ANN			2.45 (0.11)	29.16*** (0.00)	0.94 (0.33)	0.37 (0.54)	0.8 (0.37)
CU_DNN				24.3*** (0.00)	3.21* (0.07)	0.6 (0.42)	5.02** (0.02)
CS_Logit					24.1*** (0.00)	30.03*** (0.00)	36.0*** (0.00)
CS_DT						2.16 (0.14)	0.04 (0.83)
CS_ANN							2.43 (0.11)

숫자는 검정통계량, ()안의 값은 p-value

\*유의수준 10%, \*\*유의수준 5%, \*\*\*유의수준 1%에서 통계적으로 유의함

터를 생성한 경우 모형의 예측성고가 높아지는 것을 확인할 수 있다. 하지만 4배 이상의 데이터를 생성한 경우 오히려 모형의 예측성과에 악영향을 주었다. 가장 극단적인 차이를 보이는 모형은 DNN으로 4배로 데이터를 생성한 데이터 셋과 8배로 데이터를 생성한 데이터 셋 간의 예측성과 차이가 4.3%로 가장 높았다. 즉 GAN의 경우 적정수준에서 데이터를 생성해야 높은 예측성과를 가진다고 할 수 있다. 언더샘플링과 GAN을 비교하면 인공신경망과 DNN 모형에서 언더샘플링에 비해 GAN 기법의 예측성과 향상을 확인할 수 있다. 예측성과 향상은 인공신경망에서 약 0.5% DNN에서 약 0.9% 정도 향상 되었으며 1.5배, 2배로 데이터를 생성한 경우에서 예측성고가 향상되는 것을 확인하였다.

#### 4.4.6 모형별 예측성과 검증

McNemar 검증은 두 집단 간 평균 차이를 검증하는 기법으로 본 연구에서는 각 데이터 마이닝 기법과 샘플링 방법의 차이에 대한 예측성과를 확인하기 위하여 활용한다. 본 연구에서 GAN 기법의 경우 검증용 데이터 셋의 크기 차이, 학습용 데이터 셋의 크기 차이로 인해 언더샘플링과 SMOTE 기법은 비교하지 않는다.

<표 7>은 set1에서의 McNemar 검증 결과이다. 로짓, 의사결정나무, 인공신경망에서는 SMOTE 기법과 언더샘플링 기법 간 유의한 성과 차이를 보이지 못했다. 하지만 DNN에서는 유의수준 5%에서 유의한 성과차이를 보이고 있다.

## V. 결론

핀테크에 대한 높은 관심도와 더불어 핀테크 비즈니스에 대한 연구가 활발하다. 하지만 많은 핀테크 비즈니스 연구들이 시중은행의 많은 고객 수를 바탕으로 한 충분한 데이터에 기초하여 진행되었다. 이러한 기존연구는 완전히 활성화되지 않은 핀테크 비즈니스 시장의 특성을 반영하지 못한 것으로 판단하여 본 연구에서는 핀테크 비즈니스 기업의 특성인 부족한 고객 수 문제를 고려한 딥러닝 기반의 지능형 개인신용 평가모형을 제안하였다.

Lending Club 데이터를 활용하여 핀테크 비즈니스 기업이 가지는 특징인 부족한 고객 수 문제를 반영하기 위해 10,000개의 데이터 셋 5개 표본으로 랜덤추출하였다. 이후 변수선택 과정에서 단일변량분석 방법인 t-test와 다변량분석 방법인 로짓의 stepwise 방법을 활용하여 변수를 선정하였다. forward와 backward의 두 가지 방법을 통해 데이터 셋을 구성하였으며 두 가지 데이터 셋에 언더샘플링, SMOTE, GAN의 샘플링 기법을 적용하였다. 데이터 생성 기법인 SMOTE은 최근접 이웃 기법을 기반으로 하며 GAN은 딥러닝 기법으로 최근 높은 관심을 받고 있다. 본 연구에서는 SMOTE, GAN 기법을 활용하여 핀테크 비즈니스 기업이 가지는 불충분한 불량 신용등급 고객 데이터를 생성하며 극복하였고 동시에 모형에 부정적인 영향을 주는 불균형 데이터의 문제를 해결하였다.

샘플링 과정을 통해 데이터 셋은 forward + 언더샘플링, forward + SMOTE, backward + 언더샘플링, backward + SMOTE으로 생성되었으며 각각의 데이터 셋으로 CU\_Logit, CU\_DT, CU\_ANN, CU\_DNN, CS\_Logit,

CS\_DT, CS\_ANN, CS\_DNN 모형을 구축하였다. 평가용 데이터 셋의 경우 모형 간 비교의 공정성을 위해 따로 표본 추출하였다. GAN은 총 200,000개의 데이터 세트에서 따로 실험하였으며 1.5배, 2배, 4배, 8배로 데이터를 생성하여 모형을 구축하였다. GAN 기법의 경우 언더샘플링, SMOTE 기법과의 직접적인 비교는 불가능하여 비교하지 않았다.

실험 결과 backward로 변수를 선정한 CS\_DNN 모형의 예측성도가 가장 높게 나타났으며 전반적으로 DNN 모형이 높은 예측성도를 보였다. GAN 기법을 활용하여 모형을 구축한 결과 인공신경망과 DNN 모형에서 데이터의 생성정도가 1.5배, 2배의 경우 향상된 예측성도를 보였으나 4배와 8배의 경우에는 예측성도가 오히려 낮아지는 것을 확인하였다.

본 연구의 공헌도는 다음과 같다. 첫째, 핀테크 비즈니스 기업의 특성을 반영한 개인신용 평가모형을 구축하였다. 기존의 핀테크 비즈니스연구에서는 핀테크 비즈니스 데이터를 사용했으나 핀테크 비즈니스의 특성을 반영하지 않고 알고리즘 향상, 결과 변수의 다양화 등을 연구하였다. 본 연구에서는 핀테크 비즈니스 기업의 특징 중 하나인 부족한 고객수 문제를 반영하여 데이터 생성 샘플링 기법을 활용함으로써 부족한 고객 수의 문제점을 완화시키고 동시에 불균형 데이터 문제를 해결하였다. 둘째, 언더샘플링과 데이터 생성 샘플링 기법을 활용하여 데이터 셋을 구성하고 모형을 구축하였다. 기존 연구에서는 비슷한 특성을 가지는 샘플링 기법간의 비교만 이루어지고 있으며 언더샘플링과 데이터 생성 샘플링 기법의 예측성도에 대한 비교는 이루어지지 않았다. 연구결과 샘플링 기법에 따라 모형의 예측성도가 다르게 나타나며 본 연구에서는

CS\_Logit, CS\_ANN, CS\_DNN에서 높은 예측 성과를 보였다. 셋째, GAN 기법을 적용하여 모형을 구축하여 예측성가를 확인한 결과 데이터의 생성 정도에 따라 성과에 차이를 보였으며 데이터 생성을 많이 했을 경우 오히려 예측성가가 낮아지는 것을 확인하였다.

본 연구의 한계점 및 향후 연구방향은 다음과 같다. 본 연구에서는 핀테크 비즈니스 기업의 특성 중 부족한 고객 수와 불균형 데이터의 문제를 해결하기 위해 SMOTE와 딥러닝 기법인 GAN을 적용하여 데이터를 생성하였으나 데이터 셋의 크기 차이로 예측성과의 차이를 통계적으로 검증하지 못하였다. 향후 연구에서는 오버샘플링 기법간의 성과도 비교할 필요가 있으며 GAN 뿐 아니라 다양한 딥러닝 기법들을 적용해 볼 수 있을 것이다.

## 참 고 문 헌

김량형, 유동희, 김건우, “데이터마이닝 기법을 이용한 기업부실화 예측 모델 개발과 예측 성능 향상에 관한 연구”, *Information Systems Review*, 제18권, 제2호, 2016, pp. 173~198.

안철휘, 이모세, 안현철, “적대적 생성 신경망 (GAN)을 활용한 오버샘플링에 관한 연구”, 2018년 한국지능정보시스템학회 춘계학술대회 논문집, 2018, pp. 76~79.

유현선, “핀테크 비즈니스 생태계에서 IT기업의 전략”, *인터넷전자상거래연구*, 제18권, 제3호, 2018, pp. 41~69.

이근희, 유영범, 하승인, “개인신용평가 모형을 위한 딥러닝 활용에 대한 연구”, *한국경영과학회 학술대회논문집*, 2017, pp.

4042~4047.

홍승진, 이상광, 양성일, “불균형 게임데이터 문제해결을 위한 Generative Adversarial Network 기반 오버 샘플링 기법”, *대한전자공학회 하계종합학술대회*, 2017, pp. 1227~1228.

Baesens. B., Van Gestel. T., Viaene. S., Stepanova. M., Suykens. J. and Vanthienen. J., “Benchmarking state-of-the-art classification algorithms for credit scoring,” *Journal of the Operational Research Society*, Vol. 54, No. 6, 2003, pp. 627~635.

Buda. Mateusz, Atsuto Maki., and Maciej A. Mazurowski., “A systematic study of the class imbalance problem in convolutional neural networks,” *Neural Networks*, Vol. 106, 2018, pp. 249~259.

Douzas, G. and Bacao, F., “Effective data generation for imbalanced learning using conditional generative adversarial networks,” *Expert Systems with Applications*, Vol. 91, 2018, pp. 464~471.

Feng, X., Xiao, Z., Zhong, B., Qiu, J., and Dong, Y., “Dynamic ensemble classification for credit scoring using soft probability,” *Applied Soft Computing*, 65(C), 2018, pp. 139~151.

Goodfellow. I., Pouget-Abadie. J., Mirze. M., Xu. B., WardeFeley. D., Ozair. S., Courville. A. and Bengio. Y., “Generative Adversarial Nets,” *Advances in Neural Information Processing Systems*, 2014, pp. 2672~2680.



- He, H. and Garcia, E. A. "Learning from imbalanced data", *IEEE Transactions on Knowledge and Data Engineering*, Vol. 21, 2009, pp. 1263–1284.
- Hinton, G. E, Osindero, S, The, Y, "A fast learning algorithm for deep belief nets," *Neural Computation*, Vol. 18, 2006, pp. 1527–1554.
- Jeatrakul P., Wong K.W., Fung C.C., "Classification of Imbalanced Data by Combining the Complementary Neural Network and SMOTE Algorithm," *Neural Information Processing*, Vol. 6444, 2010, pp. 152~159.
- Kim, J., Shin, N., Jo, S. Y., and Kim, S. H., "Method of intrusion detection using deep neural network," Big Data and Smart Computing (BigComp), 2017 IEEE International Conference on. IEEE, 2017, pp.313–316.
- Kvamme, H., Sellereite, N., Aas, K., and Sjursen, S., "Predicting mortgage default using convolutional neural networks," *Expert Systems with Applications*, Vol. 102, 2018, pp. 207– 217.
- LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W., and Jackel, L. D, "Backpropagation applied to handwritten zip code recognition," *Neural computation*, Vol. 1, No. 4, 1989, pp.541–551.
- Lee, K. J., Heo, M. R. and Jeon, J. H., "Understanding of Fintech," *Journal of Information Systems*, Vol. 25, No. 2, 2016, pp.173–189.
- Loureiro, A, L, D., Migueis, V, Lucas, L., and da Silva, F, M., "Exploring the use of deep neural networks for sales forecasting in fashion retail," *Decision Support Systems*, Vol. 114, 2018, pp. 81–93.
- Luo. Cuicui, Desheng Wu., and Dexiang Wu., "A deep learning approach for credit scoring using credit default swaps," *Engineering Applications of Artificial Intelligence*, Vol. 65, 2017, pp. 465–470.
- Mahmoudi. Nader, Paul Docherty, Pablo Moscato, "Deep neural networks understand investors better," *Decision Support Systems*, Vol. 112. 2018, pp. 23~34.
- Tomczak, J. M. and M. Zieba., "Classification Restricted Boltzmann Machine for comprehensible credit scoring model," *Expert Systems with Applications*, Vol. 42, 2015, pp. 1789–1796.
- Xia. Yufei, Chuanzhe Liu., and Nana Liu., "Cost-sensitive boosted tree for loan evaluation in peer-to-peer lending," *Electronic Commerce Research and Applications*, Vol. 24, 2017, pp.30–49.
- Yang. Y., "Adaptive credit scoring with kernel learning methods," *European Journal of Operational Research*, Vol. 183, No. 3, 2007, pp.1521–1536.